1. INPUT DATA (UIT-VSMEC CORPUS)

Bộ dữ liệu bình luận MXH tiếng Việt
- Train: 5,548 mẫu
- Validation: 686 mẫu
- Test: 693 mẫu
(7 nhãn: Enjoyment, Disgust, Other, Sadness, Anger, Fear, Surprise)

2. TIỀN XỬ LÝ VĂN BẢN CHUYÊN SÂU (PREPROCESSING)

Chuẩn hóa bảng mã Unicode NFC (Khắc phục lỗi dấu tổ hợp bị tách rời)

Xóa URL rác & Chuyển chữ thường (lowercase)

Bảo tồn & Ánh xạ Emoticon / Emoji (:)), ^^ -> icon_vui | 😭, :((-> emoji_buon 😡 -> emoji_tuc_gian | 😱 -> emoji_so_hai)

Chuẩn hóa Teencode & Từ viết tắt MXH (ko -> không, dc -> được, wa -> quá, j -> gì...)

Rút gọn ký tự lặp kéo dài (quáaaaa -> quá, đẹpppp -> đẹp)

Tách từ ghép tiếng Việt (Word Segmentation) bằng thư viện PyVi (ViTokenizer)

3. TRÍCH XUẤT ĐẶC TRƯNG (TF-IDF VECTORIZATION)

TfidfVectorizer
Cấu hình tối ưu:
- N-gram Range: (1, 2) (bắt trọn cụm phủ định như 'không thích')
- Max features: 10,000 đặc trưng quan trọng
- Sublinear TF: True (làm mượt tần số xuất hiện)

Nguyên tắc chống rò rỉ dữ liệu (Data Leakage):
- Fit & Transform CHỈ trên tập Train
- Chỉ Transform trên tập Val và Test

4. HUẤN LUYỆN & TINH CHỈNH MÔ HÌNH (MODEL & GRIDSEARCH)

Thuật toán: Linear SVM (LinearSVC)
- Class Weight = 'balanced' (cân bằng nhãn lệch)

Tinh chỉnh siêu tham số C bằng GridSearchCV:
- Dải tìm kiếm: C ∈ [0.1, 0.3, 0.5, 0.8, 1.0, 1.5, 2.0]
- 5-Fold Stratified Cross-Validation
- Tiêu chí tối ưu: scoring = 'f1_macro'

-> Tìm ra C tối ưu nhất: C = 0.3

5. ĐÁNH GIÁ & XUẤT KẾT QUẢ (EVALUATION & INFERENCE)

Đánh giá trên tập Validation & Test:
- Test Accuracy: 59.31%
- Test Macro F1: 56.52%
- Test Weighted F1: 59.32%

Vẽ Ma trận nhầm lẫn (Confusion Matrix Heatmap)
-> Xuất file confusion_matrix.png

Bảng đối sánh hiệu năng các giá trị C
-> Xuất file c_comparison_results.csv

Dự đoán trên tập Test & Xuất file nộp:
-> predictions.csv (id, text, ground_truth, predicted_label)