PIPELINE: NHẬN DIỆN CẢM XÚC TIẾNG VIỆT (UIT-VSMEC) • TF-IDF + LINEAR SVM • NHÓM 12

BƯỚC 1 • TÌM HIỂU & CHUẨN BỊ BỘ DỮ LIỆU (DATA EXPLORATION)

• Nguồn ngữ liệu gốc: Bộ dữ liệu UIT-VSMEC (Vietnamese Social Media Emotion Corpus) gồm 6,927 bình luận Facebook.

• Phân chia phân tầng (Stratified Split): Tỷ lệ chuẩn 80 - 10 - 10 đảm bảo đủ 7 nhãn ở cả 3 tập (Train: 5,548 | Val: 686 | Test: 693).

• Không gian nhãn & Phân bố: 7 nhãn lệch mẫu nặng: Enjoyment (1,558), Disgust (1,071), Other (1,021), Sadness (947), Anger (391), Fear (318), Surprise (242).

BƯỚC 2 • TIỀN XỬ LÝ VĂN BẢN CHUYÊN SÂU (TEXT PREPROCESSING PIPELINE)

• B1. Chuẩn hóa Unicode NFC: Khắc phục lỗi phân mảnh dấu thanh tổ hợp tiếng Việt trên MXH (VD: thi´ ch -> thích).

• B2. Làm sạch cơ bản: Loại bỏ URL rác (http/www...), ký tự điều khiển lạ và chuyển toàn bộ văn bản về chữ thường (lowercase).

• B3. Bảo tồn Emoji & Emoticon: Ánh xạ icon/emoji thành token cảm xúc (:)) -> icon_vui; □, :((-> emoji_buon; □ -> emoji_tuc_gian...).

• B4. Rút gọn ký tự lặp (chạy trước): Thu gọn ký tự kéo dài nhấn mạnh về dạng chuẩn (quáaaaa -> quá, đẹpppp -> đẹp, waaa -> wa).

• B5. Chuẩn hóa Teencode (chạy sau): Ánh xạ từ viết tắt MXH về chuẩn (wa -> quá, ko -> không, dc -> được, j -> gì, cx -> cũng, bik -> biết...).

• B6. Tách từ ghép tiếng Việt (PyVi): Phân định ranh giới từ bằng ViTokenizer (thời buổi -> thời_buổi, nước mắt -> nước_mắt).

BƯỚC 3 • TRÍCH XUẤT ĐẶC TRƯNG TỪ VỰNG (TF-IDF VECTORIZATION)

• Mô hình biểu diễn: TF-IDF Vectorizer (Term Frequency - Inverse Document Frequency) trích xuất đặc trưng thống kê từ ngữ.

• Cấu hình N-gram: ngram_range = (1, 2) (bắt trọn cả từ đơn lẫn cặp 2 từ liền kề mang nghĩa phủ định: 'không thích', 'rất buồn').

• Tham số tối ưu hóa: max_features = 10,000 đặc trưng quan trọng nhất | sublinear_tf = True (làm mượt tần số xuất hiện của từ).

• Chống rò rỉ dữ liệu (No Data Leakage): fit_transform CHỈ áp dụng trên tập Train; tập Validation và Test CHỈ áp dụng transform.

BƯỚC 4 • HUẤN LUYỆN & TINH CHỈNH MÔ HÌNH (MODEL TRAINING & GRIDSEARCHCV)

• Thuật toán phân loại: Linear Support Vector Classification (LinearSVC) - Tìm siêu phẳng phân tách tối ưu lồi trong không gian 10,000 chiều.

• Cân bằng dữ liệu lệch nhãn: class_weight = 'balanced' (tự động cân chỉnh trọng số phạt nghịch đảo tần suất lớp để hỗ trợ các nhãn ít mẫu).

• Xác định độ đo mục tiêu & Tinh chỉnh: Thiết lập scoring = 'f1_macro' trong 5-Fold Stratified CV với dải C □ [0.1, 0.3, 0.5, 0.8, 1.0, 1.5, 2.0].

• Kết quả tối ưu: Tìm ra siêu tham số tối ưu nhất C = 0.3 (Rank 1, CV Macro F1: 52.43%) đạt độ cân bằng tốt nhất giữa bias và variance.

BƯỚC 5 • ĐÁNH GIÁ MÔ HÌNH & HIỂN THỊ KẾT QUẢ (EVALUATION & VISUALIZATION)

• Kết quả độ đo (Test Set): Accuracy: 58.87% (408/693 mẫu) | Macro F1-Score: 55.97% | Weighted F1-Score: 58.88%.

• Kết quả độ đo (Validation Set): Accuracy: 55.39% | Macro F1-Score: 51.81% | Weighted F1-Score: 55.54%.

• F1-Score từng nhãn (Test Set): Enjoyment: 68.21% | Sadness: 66.09% | Fear: 62.26% | Other: 52.94% | Surprise: 52.05% | Disgust: 51.56% | Anger: 38.71%.

• Trực quan hóa & Sản phẩm bàn giao: Ma trận nhầm lẫn (confusion_matrix.png phân tích các cặp dễ nhầm lẫn như Anger-Disgust), predictions.csv.