PIPELINE: NHẬN DIỆN CẢM XÚC TIẾNG VIỆT (UIT-VSMEC) • TF-IDF + LINEAR SVM • NHÓM 12

BƯỚC 1 • TÌM HIỂU & CHUẨN BỊ BỘ DỮ LIỆU (DATA EXPLORATION)

• Nguồn ngữ liệu gốc: Bộ dữ liệu UIT-VSMEC (Vietnamese Social Media Emotion Corpus) gồm 6,927 bình luận Facebook (Null = 0, Duplicate = 0).

• Phân chia phân tầng (Stratified Split): Tỷ lệ chuẩn 80 - 10 - 10 đảm bảo đủ 7 nhãn ở cả 3 tập (Train: 5,548 | Val: 686 | Test: 693).

• Không gian nhãn & Phân bố: 7 nhãn lệch mẫu nặng: Enjoyment (1,558), Disgust (1,071), Other (1,021), Sadness (947), Anger (391), Fear (318), Surprise (242).

BƯỚC 2 • TIỀN XỬ LÝ VĂN BẢN CHUYÊN SÂU (TEXT PREPROCESSING PIPELINE)

• B1. Chuẩn hóa Unicode NFC & Làm sạch: Khắc phục lỗi phân mảnh dấu thanh tổ hợp tiếng Việt (thi ́ ch -> thích) và xóa URL rác (http/www...).

• B2. Bảo tồn Emoji & Emoticon: Ánh xạ icon/emoji thành token ngữ nghĩa (:)) -> icon_vui; □, :((-> emoji_buon; □ -> emoji_tuc_gian...).

• B3. Bắt tiếng cười/khóc TRƯỚC khi rút gọn lặp: Ánh xạ kkk+, haha+, hihi+ -> icon_vui/emoji_vui trước để tránh lỗi kkk -> k -> không (phủ định).

• B4. Bảo tồn dấu câu cảm xúc & Tách dấu câu: Ánh xạ !+ -> token_than, ?+ -> token_hoi (hỗ trợ Surprise/Anger); tách dấu câu trước khi tra từ điển.

• B5. Rút gọn ký tự lặp & Chuẩn hóa Teencode: Thu gọn từ kéo dài (đẹpppp -> đẹp) và chuẩn hóa chính tả khách quan (ko, -> không, dc. -> được, vl -> vãi).

• B6. Tách từ ghép tiếng Việt (PyVi): Phân định ranh giới từ bằng ViTokenizer (thời buổi -> thời_buổi, nước mắt -> nước_mắt).

BƯỚC 3 • TRÍCH XUẤT ĐẶC TRƯNG KÉP (FEATUREUNION: WORD + CHAR_WB TF-IDF)

• Kiến trúc FeatureUnion (tương tự Mục 5.2 bài báo gốc UIT): Kết hợp song song đặc trưng từ vựng (Word TF-IDF) và hình thái ký tự (Char_wb TF-IDF).

• Nhánh 1 - Word TF-IDF: ngram_range = (1, 2) bắt từ đơn và cụm phủ định ('không_thích', 'quá_buồn') | min_df = 2, max_df = 0.9 | sublinear_tf = True.

• Nhánh 2 - Char_wb TF-IDF: analyzer = 'char_wb', ngram_range = (2, 5) bắt biến thể teencode/lỗi chính tả trong từ | min_df = 2 | sublinear_tf = True.

• Chống rò rỉ dữ liệu (Zero Data Leakage): Đóng gói FeatureUnion và LinearSVC vào sklearn.pipeline.Pipeline (chỉ fit trên fold Train khi CV).

BƯỚC 4 • HUẤN LUYỆN & TINH CHỈNH MÔ HÌNH (MODEL TRAINING & GRIDSEARCHCV)

• Thuật toán phân loại: Linear Support Vector Classification (LinearSVC, random_state = 42, max_iter = 5000).

• Cân bằng dữ liệu lệch nhãn: class_weight = 'balanced' (tự động cân chỉnh trọng số phạt nghịch đảo tần suất lớp giúp tăng vọt F1 ở các nhãn thiểu số).

• Xác định độ đo mục tiêu & Tinh chỉnh: Thiết lập scoring = 'f1_macro' trong 5-Fold StratifiedKFold với dải C □ [0.05, 0.1, 0.2, 0.3, 0.5, 1.0].

• Kết quả tối ưu: Tìm ra siêu tham số tối ưu C = 0.3 (Rank 1, Best 5-Fold CV Macro F1 = 53.91%) vừa chống học vẹt (overfit) vừa chống underfit.

BƯỚC 5 • ĐÁNH GIÁ MÔ HÌNH & HIỂN THỊ KẾT QUẢ (EVALUATION & VISUALIZATION)

• Giao thức 1 (Train-Only 5,548 mẫu - Chuẩn UIT): Test Acc: 60.89% | Macro F1: 57.75% | Weighted F1: 60.92% (Vượt SVM UIT +4.05% & CNN UIT +1.18%).

• Giao thức 2 (Train + Val 6,234 mẫu - Mở rộng): Test Acc: 61.04% | Macro F1: 58.24% | Weighted F1: 61.16% (Bứt phá +1.42% WF1 so với CNN UIT).

• Per-Class F1 (Test - Train-Only): Enjoyment: 69.61% | Sadness: 67.83% | Fear: 64.00% | Disgust: 56.83% | Surprise: 56.76% | Other: 53.94% | Anger: 35.29%.

• Trực quan hóa & Bàn giao: Bảng Ablation Study bóc tách đóng góp, Confusion Matrix (confusion_matrix.png), file dự đoán predictions.csv (693 dòng).